Tarea M26-CD- YAIR PALOMARES

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import os
```

```
os.chdir("C:/Users/yair_/OneDrive/Desktop/Ciencia de Datos/Módulo 26 - Clustering jerárquico y PCA")
data = pd.read_csv("Amazon.csv")
data
```

	Unnamed: 0	Velocidad Entrega	Precio	Durabilidad	Imagen Producto	Valor Educativo	Servicio Retorno	Tamano Paquete	Calidad Producto	Numero Estrellas
0	Adam	205	3	345	235	24	23	26	21	17
1	Anna	9	15	315	33	25	4	42	215	28
2	Bernard	17	26	285	3	43	27	41	26	33
3	Edward	135	5	355	295	18	23	39	195	17
4	Emilia	3	45	48	39	34	46	225	34	43
...	...	...	...	...	...	...	...	...	...	...
95	Teofan	3	8	32	25	7	21	42	17	1
96	Teofil	305	25	46	24	33	28	355	26	45
97	Teofila	1	14	26	25	24	27	42	185	23
98	Teon	155	11	335	34	26	29	42	215	27
99	Teresa	125	9	45	25	22	3	3	22	18

100 rows × 10 columns

```
#Normalizar los datos porque las escalas si están muy diferentes
from sklearn.preprocessing import normalize
data_scaled = data.drop("Unnamed: 0", axis=1)
data_scaled = normalize(data_scaled)
#Hacemos el arreglo normalizado un data frame
columns_name = list(data.columns)
columns_name.pop(0)
data_scaled = pd.DataFrame(data_scaled, columns = columns_name)
```

```python
import scipy.cluster.hierarchy as shc
plt.figure(figsize=(10,7))
plt.title("Dendograma")
dend = shc.dendrogram(shc.linkage(data_scaled, method="ward"))
```

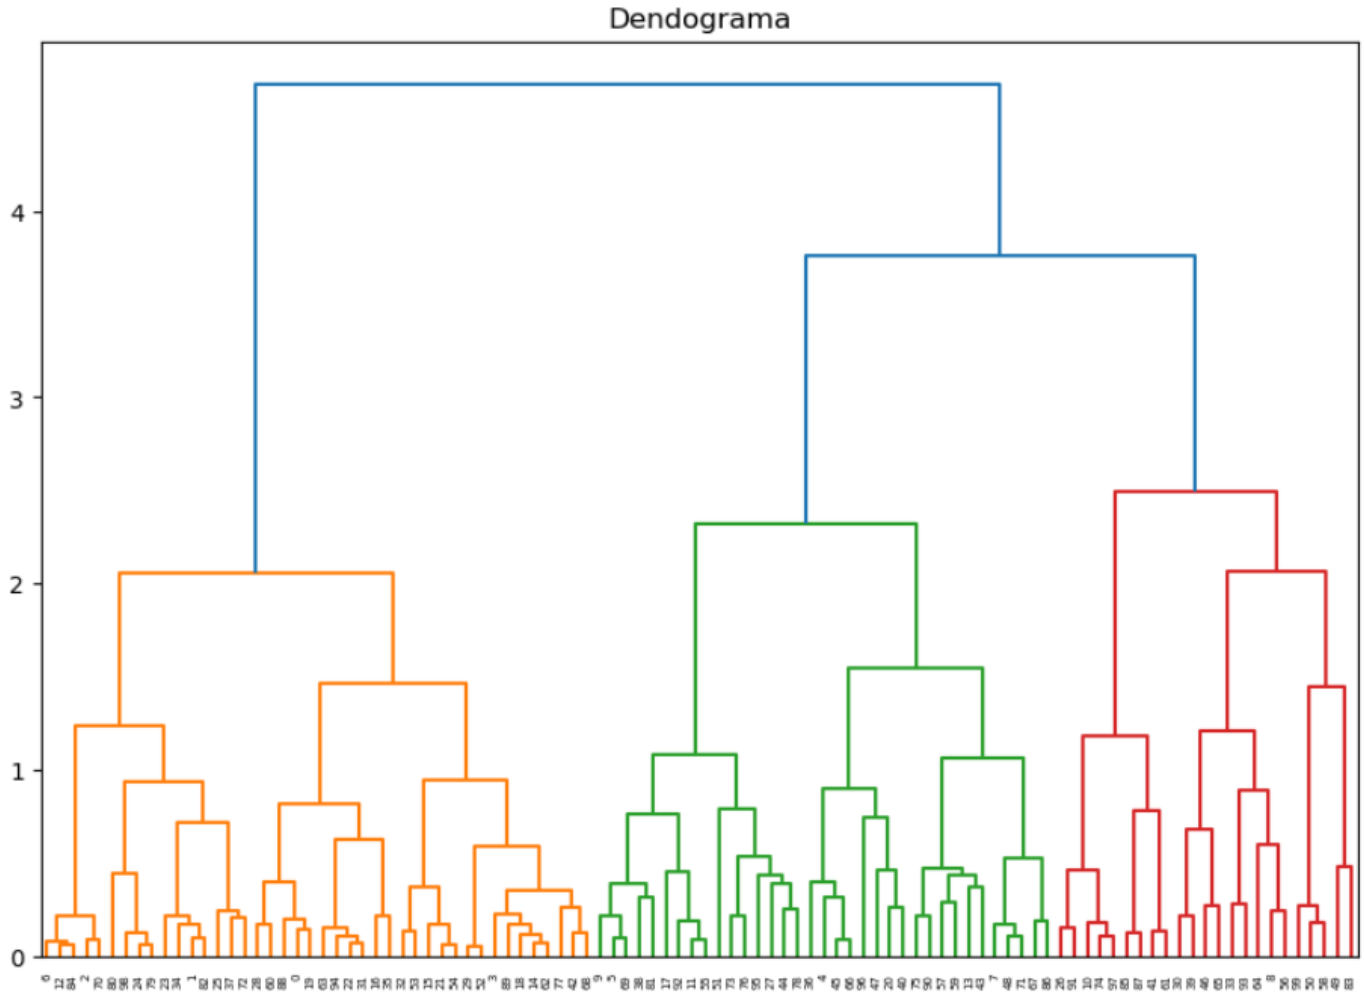


```python
colores_unicos = set(dend["color_list"])
colores_unicos
```

```
{'C0', 'C1', 'C2', 'C3'}
```

```python
#Se agrega una linea horizontal donde está el valor de los clustering óptimos
plt.figure(figsize=(10,7))
plt.title("Dendograma")
dend = shc.dendrogram(shc.linkage(data_scaled, method="ward"))
plt.axhline(y=3, color="r", linestyle="--")
```

```
<matplotlib.lines.Line2D at 0x2485df47e50>
```

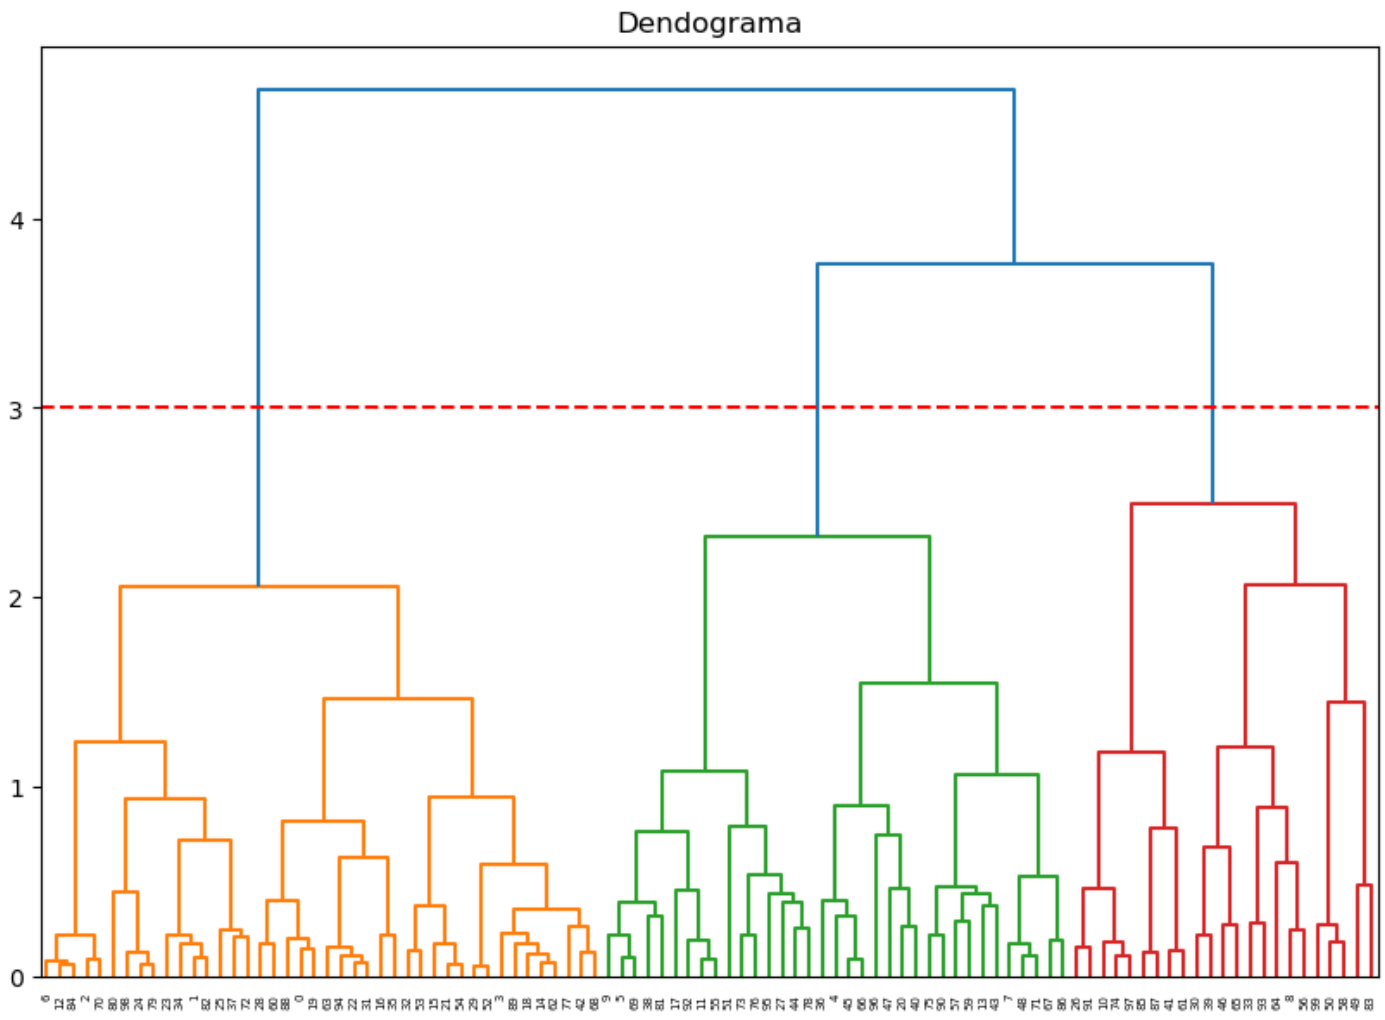

```python
#Se etiqueta a cada dato con su grupo asignado
from sklearn.cluster import AgglomerativeClustering
cluster = AgglomerativeClustering(n_clusters=3, affinity="euclidean", linkage="ward")
grupos = cluster.fit_predict(data_scaled)
grupos
```

```
D:\Anaconda\Lib\site-packages\sklearn\cluster\_agglomerative.py:983: FutureWarning: Attribute `affinity` was deprecated in version 1.2 and will be remov
ed in 1.4. Use `metric` instead
  warnings.warn(
```

```
array([1, 1, 1, 1, 2, 2, 1, 2, 0, 2, 0, 2, 1, 2, 1, 1, 1, 2, 1, 1, 2, 1,
       1, 1, 1, 1, 0, 2, 1, 1, 0, 1, 1, 0, 1, 1, 2, 1, 2, 0, 2, 0, 1, 2,
       2, 2, 0, 2, 2, 0, 0, 2, 1, 1, 1, 2, 0, 2, 0, 2, 1, 0, 1, 1, 0, 0,
       2, 2, 1, 2, 1, 2, 1, 2, 0, 2, 2, 1, 2, 1, 1, 2, 1, 0, 1, 0, 2, 0,
       1, 1, 2, 0, 2, 0, 1, 2, 2, 0, 1, 0], dtype=int64)
```

```python
#Separación de grupos mediante PCA
campos = data_scaled.values
from sklearn import decomposition
pca = decomposition.PCA(n_components=2)
pca.fit(campos)
campos = pca.transform(campos)
campos
```

```
array([[-0.39993219,  0.06035374],
       [-0.40829583, -0.06402268],
       [-0.49703182, -0.35955286],
       [-0.33996675,  0.18434501],
       [ 0.58207751, -0.38797653],
       [ 0.1723403 , -0.52962573],
       [-0.56528441, -0.33770585],
       [ 0.5335887 ,  0.06994712],
       [ 0.09981604,  0.47165743],
       [ 0.22195207, -0.56503313],
       [ 0.08274005,  0.39712712],
       [-0.00143465, -0.48936583],
       [-0.57292039, -0.35927774],
       [ 0.51350639,  0.01301312],
       [-0.35272162,  0.20639728],
       [-0.4688626 ,  0.0168001 ],
       [-0.25142488,  0.04599019],
       [-0.05456876, -0.22302796],
       [-0.36123131,  0.20553368],
       [-0.41087067,  0.02173183],
       [ 0.54207892, -0.03308916],
       [-0.5138909 , -0.0900875 ],
```

```
#Se grafican los datos ya con PCA
plt.figure(figsize=(10,7))
plt.scatter(campos[:,0], campos[:,1], c=cluster.labels_)
```

```
<matplotlib.collections.PathCollection at 0x2485df6e410>
```

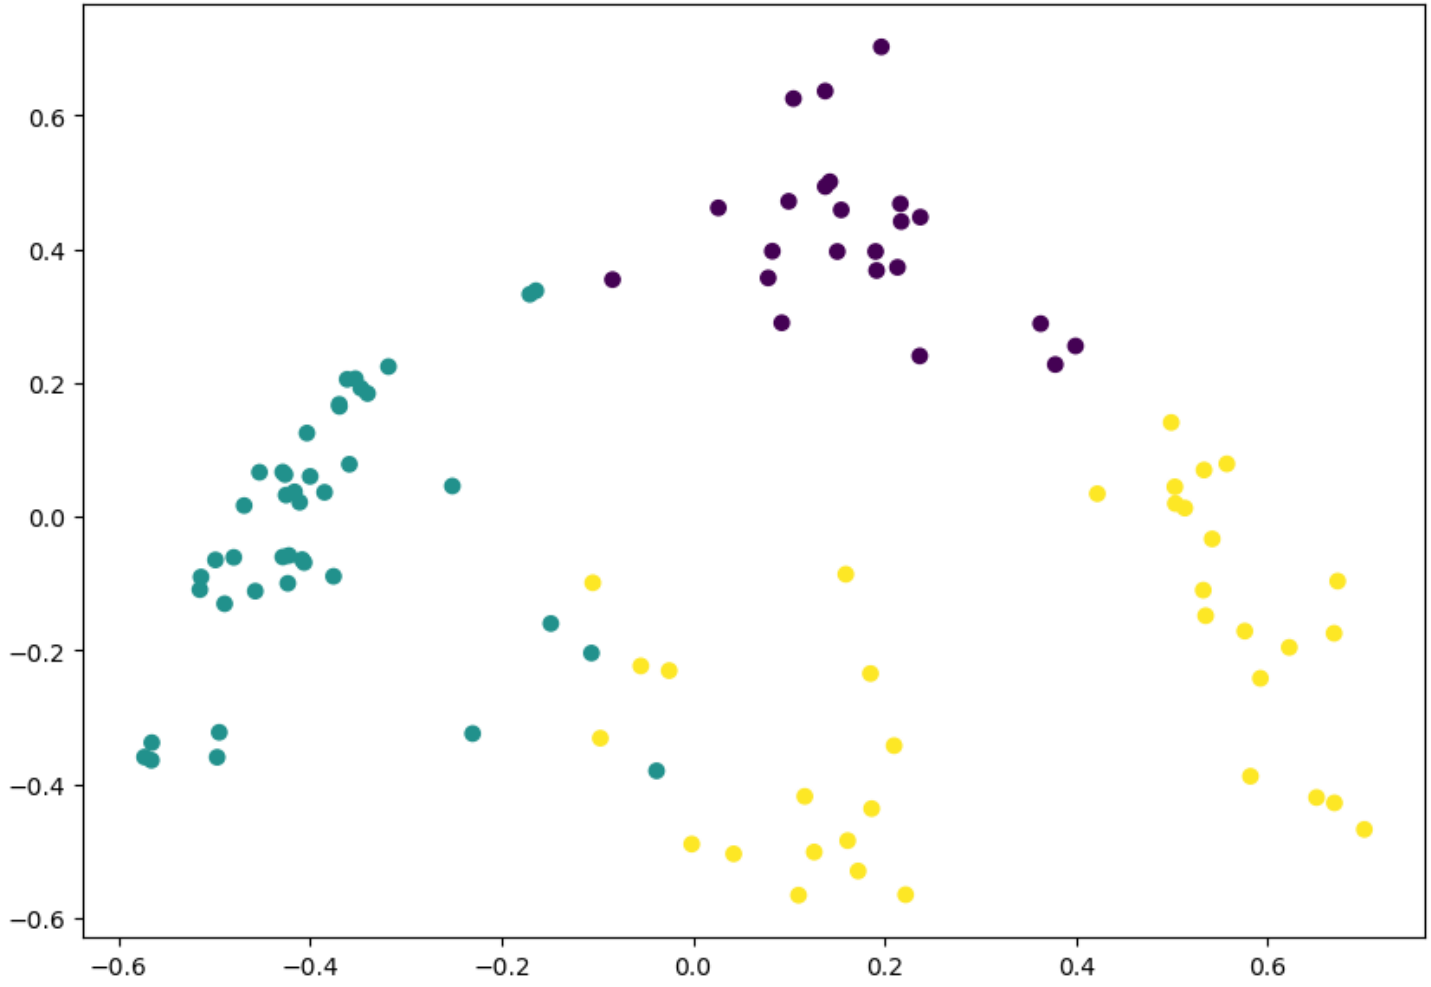


```
#Convertimos la clasificación de los datos a un dataframe
dataframe = pd.DataFrame(grupos, columns = ["grupo"])
#Se unen los dos dataframe para visualizar en la base de datos a que grupo pertenece cada observación
dataframe2 = pd.concat([data, dataframe], axis=1, join="inner")
```

```
#Para conclusiones de la práctica
recomendaciones = dataframe2[dataframe2["Unnamed: 0"].isin(["Salome", "Stephania", "Lydia"])]
recomendaciones
```

	Unnamed: 0	Velocidad Entrega	Precio	Durabilidad	Imagen Producto	Valor Educativo	Servicio Retorno	Tamano Paquete	Calidad Producto	Numero Estrellas	grupo
54	Lydia	19	4	435	145	16	21	28	185	24	1
81	Salome	17	23	275	41	4	44	315	28	32	2
89	Stephania	215	125	465	315	34	4	37	305	45	1

```
import seaborn as sns
fig, axes = plt.subplots(nrows=3, ncols=3, figsize=(12, 12))
dataframe2["grupo"] = dataframe2["grupo"].astype("category")
columnas_name = list(dataframe2.columns)
columnas_name.remove("Unnamed: 0")
columnas_name.remove("grupo")
cont = 0
for i in range(3):
    for j in range(3):
        sns.boxplot(data=dataframe2, x=columnas_name[cont], y="grupo", ax = axes[i,j])
        axes[0, 0].set_title(columnas_name[cont])
        cont = cont + 1
plt.show()
```

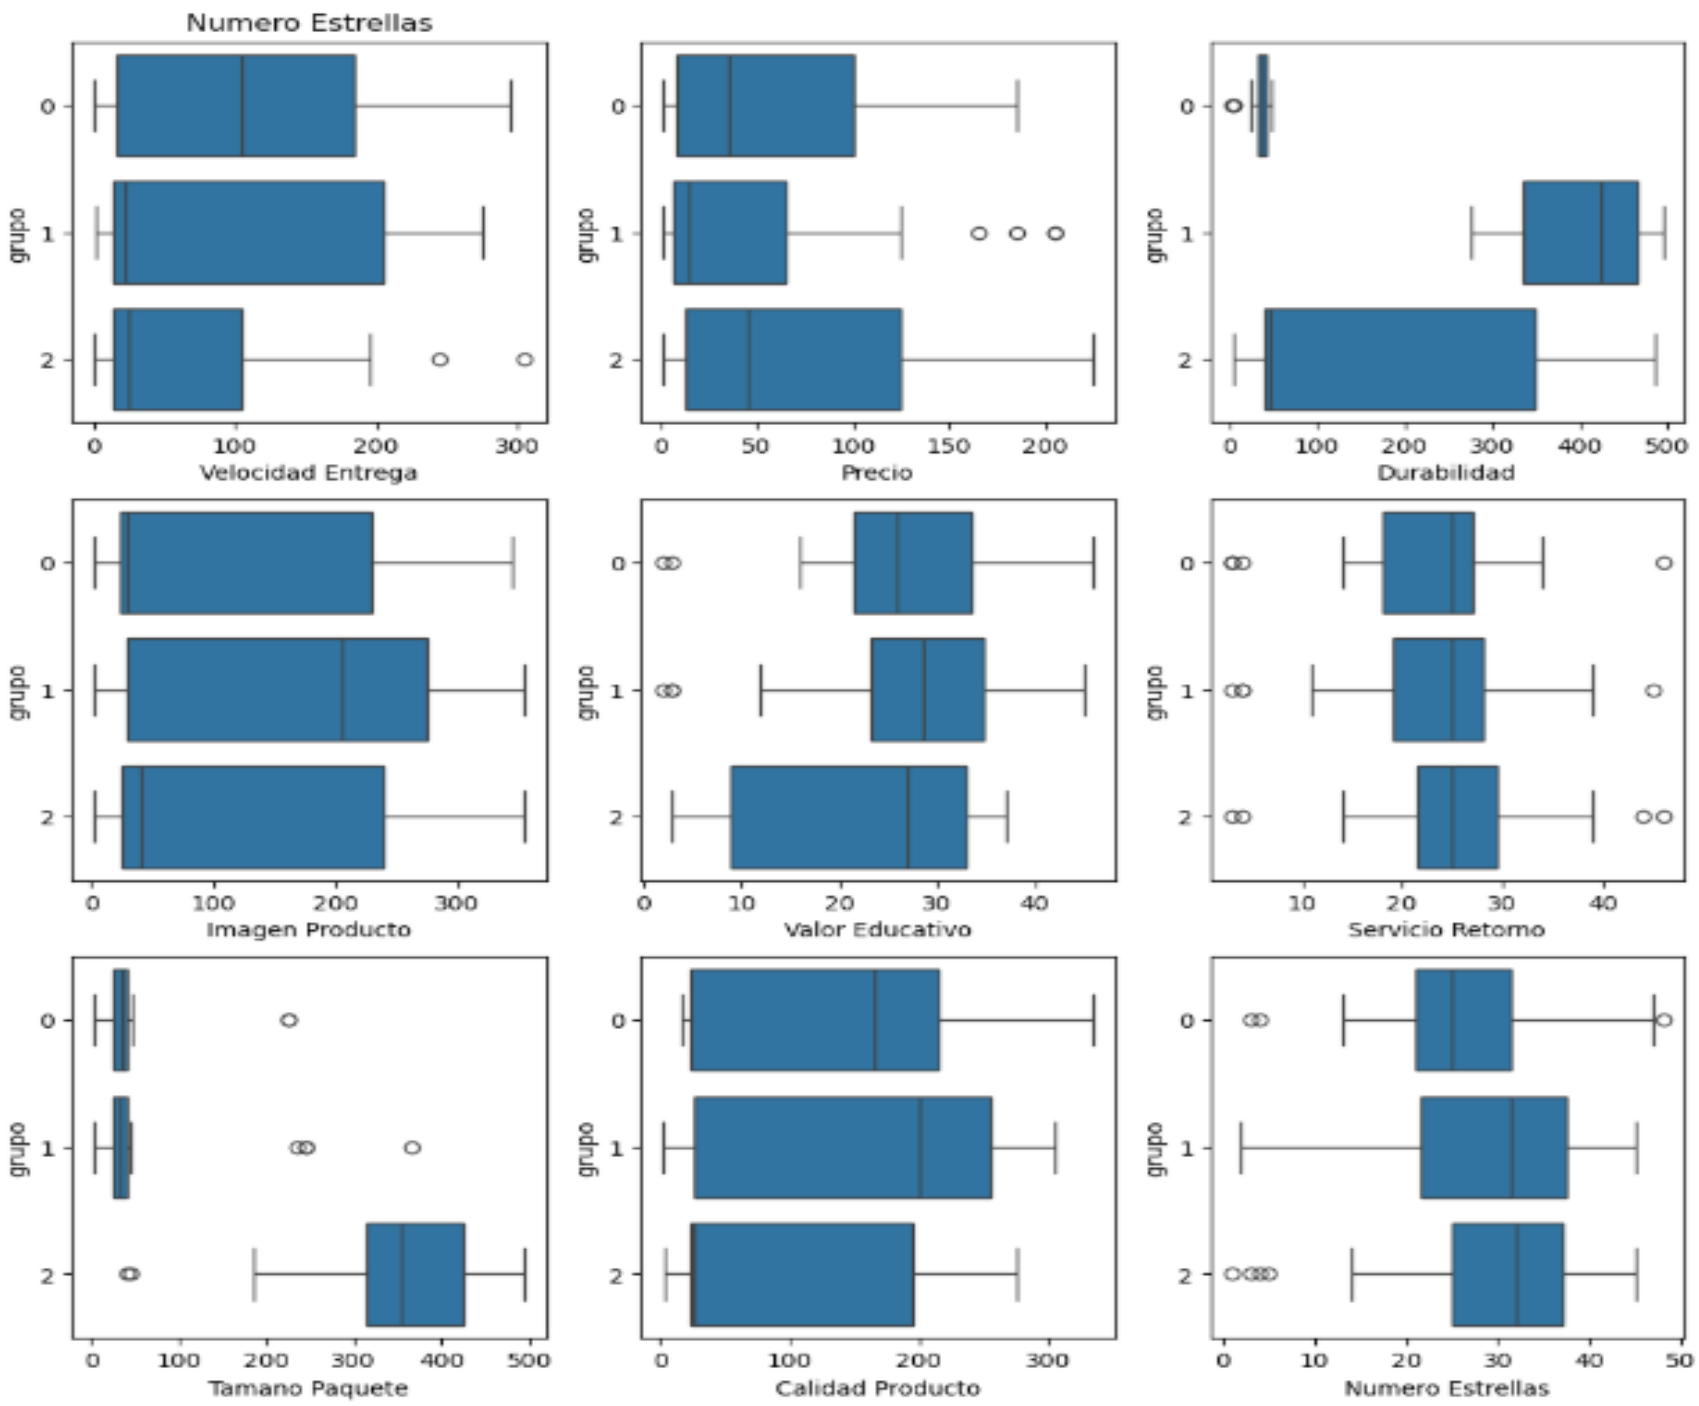
Numero Estrellas
grupo
Velocidad Entrega
Precio
Durabilidad
Imagen Producto
Valor Educativo
Servicio Retorno
Tamano Paquete
Calidad Producto
Numero Estrellas

- Con base en los resultados de su análisis, ¿qué productos recomendaría a Salomé? ¿Qué productos recomendaría a Stephanía? ¿Qué productos recomendaría a Lydia? La respuesta debe estar reflejada en función de otros clientes. Por ejemplo, "Recomendaría a Salomé los mismos productos que compró XXXXX". Dé nombres de clientes en cada caso. Expliqué claramente sus conclusiones.

```
# ¿Qué productos recomendarías a Salomé?
recomendaciones_enfoque_salome = dataframe2[dataframe2["grupo"] == 2]
print("Salomé pertenece al grupo 2, por lo tanto recomendaría los tipos de productos que frecuentan personas como:\n", recomendaciones_enfoque_salome["U
print()
print("De acuerdo con los datos, el grupo 2 suele consumir productos de un mayor tamaño aunque tengan un mayor precio. Así como también no dan tanta imp
```

```
Salomé pertenece al grupo 2, por lo tanto recomendaría los tipos de productos que frecuentan personas como:
 ['Emilia' 'Fabian' 'Frank' 'Gabriel' 'Henry' 'Isabelle' 'Eugenia'
 'Evdokia' 'Florence' 'Jeremiah' 'Joachim' 'Santiago' 'Justin' 'Kalyna'
 'Larissa' 'Leon' 'Leonard' 'Leo' 'Magdalyna' 'Marcel' 'Maria' 'Maryna'
 'Matthew' 'Maya' 'Melania' 'Michael' 'Mina' 'Monica' 'Myron' 'Salome'
 'Sebastian' 'Susanna' 'Sylvester' 'Teofan' 'Teofil']

De acuerdo con los datos, el grupo 2 suele consumir productos de un mayor tamaño aunque tengan un mayor precio. Así como también no dan tanta importanci
a al valor educativo, velocidad de entrega, ni durabilidad.
```

```
# ¿Qué productos recomendarías a Stephanía?
recomendaciones_enfoque_stephania = dataframe2[dataframe2["grupo"] == 1]
print("Stephanía pertenece al grupo 1, por lo tanto recomendaría los tipos de productos que frecuentan personas como:\n", recomendaciones_enfoque_stepha
print()
print("De acuerdo con los datos, el grupo 1 compra productos baratos y que tengan una gran durabilidad. De igual manera, este tipo de clientes suelen pr
```

```
Stephanía pertenece al grupo 1, por lo tanto recomendaría los tipos de productos que frecuentan personas como:
 ['Adam' 'Anna' 'Bernard' 'Edward' 'Philip' 'Irene' 'Isidore' 'Joseph'
 'Eugene' 'Eunice' 'Eva' 'Fedir' 'Felix' 'Fialka' 'Flavia' 'Flora'
 'Hannah' 'Helen' 'Hilary' 'Lourdes' 'Ivan' 'Jacob' 'Jervis' 'Judith'
 'Louise' 'Lubomyr' 'Lydia' 'Marian' 'Markian' 'Marko' 'Maura'
 'Maximillian' 'Methodius' 'Mykyta' 'Myroslav' 'Myroslava' 'Samuel'
 'Sarah' 'Stephan' 'Stephania' 'Theodore' 'Teon']

De acuerdo con los datos, el grupo 1 compra productos baratos y que tengan una gran durabilidad. De igual manera, este tipo de clientes suelen preferir
paquetes de tamaños pequeños
```

```python
# ¿Qué productos recomendarías a Lydia?
print("Lydia pertence al mismo grupo que Stephanía, por lo que serían las mismas recomendaciones que a ella, con respecto al grupo 1")
```

```
Lydia pertence al mismo grupo que Stephanía, por lo que serían las mismas recomendaciones que a ella, con respecto al grupo 1
```